

基于 Spring AI 与云端 Dual-Agent 智能政务咨询与导办系统

实训研发全景技术答辩汇报

 答辩人

计算机系 / 软件工程专业答辩组

 核心架构技术栈

Spring Boot 3 + Spring AI 1.0 + SQLite
FTS5 + ONNX

 答辩年份与状态

2026 年度答辩 · 代码已开源交付

01

01 选题背景与意义

政务深水区痛点剖析、长尾政策法规检索困境与系统性能指标矩阵。

02

02 研究思路与理论

三层微服务拓扑、RAG 6 步流转机制、四大后端工程机制与基准压测。

03

03 研究内容与展示

Spring AI 编排、CPU 语义精排、前端客户端实机展示与四大场景实测。

04

04 总结分析与展望

全栈交付成果、四阶段研发里程碑、工程反思与未来 SLM 演进规划。

01

选题背景与意义

🔥 传统政务咨询核心痛点

- **4.4GB 长尾政策法规检索难**：常规分词缺乏政务专有词典，短词漏召回率高
- **通用大模型幻觉频发**：缺乏权威知识溯源，无法支撑政务办事的严肃性要求
- **政务系统高度隔离**：外部服务调用易被 Mixed Content 协议封锁与跨域阻断

💡 本系统核心破局方案

- **现代反应式架构**：基于 Spring Boot 3 与 Spring AI 1.0 打造 Dual-Agent 引擎
- **零显卡轻量 RAG**：自研 SQLite FTS5 短词精召 + 纯 CPU ONNX 语义精排管道
- **零侵入沙箱前端**：Shadow DOM 隔离容器，穿透 Mixed Content，首字延迟 < 1.2s

- **语义鸿沟**：群众口语化长句提问与政务规章用词差异巨大，传统全文检索粗召回漏检率高
- **算力鸿沟**：主流深度重排模型依赖独立 GPU 算力，单机私有化部署运维成本极高
- **协议鸿沟**：政务大厅 HTTPS 环境严格限制非安全连接，跨域请求极易被浏览器拦截
- **核心矛盾**：在高准确率、低延迟响应、零显卡算力与高隔离接入之间达成工程平衡

延时指标

毫秒级流式低延迟

- 基于 SSE 单向流式推流
- 首字延迟严格控制在 1.2s 内
- 单核并发稳态吞吐 > 20 QPS

准确度

权威精准与零幻觉

- 构建闭环 RAG 检索增强回路
- 八大政务要素标准化解析
- 答复严格绑定法规来源与直达链接

部署成本

零显卡轻量化部署

- 本地 SQLite FTS5 嵌入式存储
- CPU 级 ONNX Runtime 模型加速
- 单机低配服务器开箱即用

前端隔离

零侵入沙箱前端容器

- Shadow DOM 样式绝对物理隔离
- 油猴网络穿透 Mixed Content
- 全场景政务无缝悬浮导办

📖 检索数据库

SQLite FTS5 嵌入式存储，替代 ES 集群，单机零外部依赖与极低冷启动延迟。

🧠 语义重排推理

CPU ONNX Runtime 跑 bge-reranker，推理稳定在 110ms，彻底摆脱显卡硬件绑定。

🤖 AI 编排框架

采用 **Spring AI 1.0** 最新规范，具备反应式流式编排与 AOP 切面拦截能力。

🛡️ 安全合规审计

基于 Advisor 切面打造 **AuditLoggingAdvisor**，全链路 Token 与敏感词无感审计。

⚡ 推流通信协议

采用 **SSE** 单向长连接推流，相比 WebSocket 更轻量，内置原生重连与心跳保活。

✂️ 客户端接入形态

Shadow DOM 沙箱隔离 + GM 越狱网络调用，彻底解决样式污染与混合内容拦截。

02

研究思路与理论

🏗️ 架构拓扑分层

- [客户端展现层]
 - └ Shadow DOM 悬浮外挂 (叻仔)
 - | (SSE 流式推流 / POST)
- [服务网关控制层]
 - └ Spring Boot 3 Controller (REST/SSE)
 - |
- [核心计算双引擎]
 - └ 引擎A: RAG 检索增强引擎 (FTS5 + ONNX)
 - └ 引擎B: Spring AI 决策推理引擎 (ChatClient)
 - |
- [底层数据仓储层]
 - └ 4.4GB 结构化政务知识库 + FTS5 倒排索引

⚙️ 核心架构逻辑

- **展现层**: Shadow DOM 悬浮智能体外挂, 与政务大厅宿主完全隔离
- **控制层**: Spring Boot 3 REST 与 SSE 统一服务网关, 承接全链路请求
- **双引擎层**: RAG 检索增强引擎 + Spring AI 决策推理引擎协同调度
- **数据层**: 4.4GB 结构化政务知识库与 SQLite FTS5 倒排索引单机常驻
- **核心特征**: 高内聚低耦合、零外部中间件依赖、全链路反应式推流

01

提问分词

QueryCompiler 语法清洗与 jieba 精准短词切分。

02

倒排粗召

基于 SQLite FTS5 倒排检索，快速召回候选池 Top-50。

03

语义精排

CPU ONNX 调度 bge-reranker 计算相关度，截取 Top-5。

04

要素装配

提取八大政务要素，根据模板动态注入 System Prompt。

05

流式推理

ChatClient Fluent API 异步流式调度，Advisor 切面遥测。

06

流式渲染

服务端 SSE 持续下推数据帧，前端打字机无损渲染。

🛡️ Advisor AOP 切面架构

深度集成 Spring AI Advisor 规范，打造 AuditLoggingAdvisor 切面，零侵入捕获 Token 消耗、执行耗时与敏感词审计。

🌊 反应式背压与缓冲调优

调优 WebClient 内存配置，将 Netty 默认 256KB 缓冲区升至 64MB，完美抵御 4.4GB 知识大块注入时的溢出风险。

🔄 状态机驱动的意图消歧

针对多轮模糊咨询（如公积金提取多重分支），设计有限状态机跟踪多轮对话 Slots，主动发起动态追问澄清。

🕸️ 政务知识拓扑层级校验

构建政务法规与办事层级前后置依赖有向图（DAG），在导办输出前校验前置材料齐备性，防止错办漏办。

📊 核心指标基准

- 原始政务知识量：**4.4GB**
- 全文检索粗召候选集：**Top-50**
- 语义精排置信截断：**Top-5**
- 政务直达链接有效率：**100%**
- 单机稳态并发能力：**> 20 QPS**
- JVM 稳态堆内存：**< 256MB**

110 ms

CPU 语义精排耗时

普通 2 核 CPU 环境下，50 条候选集精排稳定在 110ms 内，加速达 300%。

1.15 s

端到端首字流式延迟

从前端发送到屏幕吐出首字平均仅 1.15 秒，JVM 堆内存占用 < 256MB。

03

研究内容与展示

💻 ChatClient 流式编排源码

```
return chatClient.prompt()
    .system(s -> s.text(ragContextPrompt))
    .user(userQuestion)
    .advisors(new AuditLoggingAdvisor())
    .stream()
    .content()
    .map(token -> ServerSentEvent.builder(token)
        .event("message")
        .build());
```

🚀 流式全生命周期治理

- ChatClient Fluent API 编排：统一封装 Prompt、System 上下文与参数控制
- SSE 全生命周期流式调度：管理连接建立、数据推流、心跳维持与异常熔断
- 八大政务要素结构化输出：自动解析事项名称、办理材料、窗口地点与直达链接

512

512-Token 滑窗切分

针对 4.4GB 原始长文本，采用 512 字符滑窗切块并保留 10% 上下文重叠，避免政务条款关键条件被截断丢失。

FTS5

倒排短词召回优化

定制 jieba + unicode61 分词语法，解决专有名词单字漏召回 Bug，短词粗召命中率跃升至 96.8%。

110ms

纯 CPU ONNX 跨编码精排

将 bge-reranker-base 转换为 ONNX 计算图，纯 CPU 环境下并行计算，兼顾语义深度与极致计算效率。



▲ 真实运行实测：“叻仔”广州市政务智能导办悬浮客户端

Shadow DOM 沙箱

封装为独立 Web Component，与政务大厅宿主绝对物理隔离，零样式污染与冲突。

GM 越狱穿透

利用油猴 GM_xmlHttpRequest 突破浏览器安全限制，彻底打通 HTTPS 到 HTTP 通信。

轻量流式渲染

自研 12KB 极简纯 JS 解析器，支持 SSE 打字机渐进渲染与 XSS 严格白名单过滤。

人性化体验调优

滚轮横向滑动映射（历史提问/推荐主题）、默认折叠为右下角胶囊、一键清空与重置。

场景一

身份证换领与申领

精准给出异地换领材料清单（户口簿、居住证）、预约窗口地点、收费标准（20元）及直达预约链接。

场景二

住房公积金提取消歧

自动识别口语化模糊意图，通过有限状态机主动追问用户属于“离职提取”还是“购房提取”，精准指引。

场景三

社保卡补办与异地就医

智能指引线上挂失、线下网点即时制卡流程，同步附送“医保跨省异地就医备案”官方小程序直达路径。

场景四

容错检索与口语化引导

用户输入错别字或方言俚语时，结合拼音容错与向量语义相似度自适应纠错，导办准确率达 98.2%。

01 分词短词漏召回排查

- **现象：**检索“中公教育”无法召回
- **排查：**jieba 默认分词致倒排索引断裂
- **方案：**重构 QueryCompiler 与专有词典

02 WebClient 内存溢出破解

- **现象：**长文注入报 256KB 缓冲溢出
- **排查：**Netty 默认缓冲上限过小
- **方案：**调优 ExchangeStrategies 至 64MB

03 SSE 游离连接泄露治理

- **现象：**客户端异常断连服务端连接残留
- **排查：**缺失心跳与异常注销回调
- **方案：**建立 Heartbeat 与超时兜底回收

04 滚轮横向滑动适配攻坚

- **现象：**提问历史水平排布无法滚轮滑动
- **排查：**原生垂直滚轮事件未映射
- **方案：**捕获 WheelEvent 动态转接 scrollLeft

04

总结分析与展望

🏆 项目总体交付评价

本项目成功构建了一套高可用、低成本、强落地的智能政务导办闭环系统。后端深度实践 Spring Boot 3 与 Spring AI 1.0 前沿技术栈，攻克了长文本切分、短词召回与 CPU 语义精排；前端通过油猴脚本与 Shadow DOM 实现零侵入即插即用，全面打通政务数字化服务的“最后一公里”。

⚙️ 70% 后端硬核

攻克 SQLite FTS5 深度分词与 CPU 级重排推理。

🧑‍🎨 30% 前端精雕

突破 Mixed Content 限制，实现极致人性化交互。

💡 0 显卡低成本

单核低配服务器实现 1.15s 流式响应。

📦 规范工程交付

全链路审计日志打通，GitHub 规范开源维护。

2026.03

阶段一：技术预研

- 搭建 Spring Boot 3 底座
- 4.4GB 政务语料清洗与入库

2026.05

阶段二：算法攻坚

- 构建 SQLite FTS5 倒排索引
- 完成 ONNX 模型转换与 CPU 精排

2026.07

阶段三：流式与前端

- 打通 SSE 端到端推流管道
- 编写油猴插件与 Shadow DOM 沙箱

2026.09

阶段四：交付与上线

- 突破 Mixed Content 与滚轮映射
- 全链路性能压测与 GitHub 交付

不足一

高并发 CPU 排队延迟

纯 CPU 精排在超 50 并发请求涌入时 CPU 利用率接近饱和，后续需引入两级 LRU 本地缓存。

不足二

单机 SQLite 扩展瓶颈

SQLite 适合单机低成本部署，未来若向跨节点集群演进，需向 PGVector 向量引擎平滑过渡。

不足三

多轮消歧上下文开销

当前多轮对话完整保留上下文会带来 Token 消耗累积，未来可引入轻量 Agent 定期压缩摘要。

不足四

移动端自适应排版深度

目前主要针对 PC 端政务大厅做了高精度适配，移动端政务 App 的响应式细节仍需深化。

演进一

端侧本地 SLM 小模型

探索在本地端侧部署 1B-3B 级轻量化小模型，满足涉密专网与全脱网环境下的政务咨询办理需求。

演进二

由政务导办跃升代办

进一步打通各政务系统 OpenAPI 经办接口，在获悉用户授权后直接代为填写表单并提交初审。

演进三

多模态材料识别 OCR

融合 OCR 图像识别（自动提取身份证/户口本信息）与双向语音对讲，辅助老年群体无障碍办事。

演进四

跨部门 Agent 协同调度

围绕公安、税务、人社、医保等不同部门打造专业 Sub-Agent，通过协同中枢实现一站式直办。

05

总结

📄 项目规范与开源声明

本答辩项目由本人独立结合实训与毕业设计工程实践全栈研发制作，系统源代码已全量开源托管于 GitHub 仓库，遵循开源规范。

1. 后端工程基于 Spring Boot 3 与 Spring AI 1.0 现代微服务架构，攻克大数据量检索与反应式流式编排；
2. 知识库数据经过权威脱敏，所有业务导办条目均可精准追溯至国家与地方政务服务网公开法规。

🔗 代码仓库与现场交流

GitHub 开源地址：

<https://github.com/dfsahdsfzyuasdgiu/spring-ai-gov-service>

现场演示系统：已在本地与云端沙箱就绪，随时支持专家随机抽题测试导办与流式性能！

